

Day1 데이터 수집 미니 파이프라인

- pytest와 Ruff기 수집과 스키마 검증 / CSV, Parquet 저장 비교

```
(.venv) gayeon@sunggayeonui-MacBookPro data-project % clear
python "day1_종합실습 /pipeline.py"

=====
API 비동기 수집 결과
=====
[성공] open_meteo      1071.58 ms
[성공] countries_dev  1582.47 ms
[성공] ip_api         159.22 ms
=====

전체 동시 수집 시간: 1583.96 ms
정상 응답 API      : 3/3개

=====
Pydantic 스키마 검증 결과
=====
[검증 통과] open_meteo
[검증 통과] countries_dev
[검증 통과] ip_api
=====

검증 통과 API: 3/3개

=====
CSV · Parquet 저장 성능 비교
=====
형식           쓰기 (ms)      읽기 (ms)      크기 (bytes)
-----
CSV            11.296         3.344         7,046
Parquet       28.963        42.039        10,266
=====

Day1 API 비동기 파이프라인 최종 결과
=====
API 정상 수집   : 3/3개
스키마 검증     : 3/3개
저장 행 수      : 74건
CSV 파일        : /Users/gayeon/data-project/data-project/day1_종합실습/output/api_data.csv
Parquet 파일    : /Users/gayeon/data-project/data-project/day1_종합실습/output/api_data.parquet
오류 기록       : /Users/gayeon/data-project/data-project/day1_종합실습/output/validation_errors.json
( )
```

- pytest와 Ruff

```
(.venv) gayeon@sunggayeonui-MacBookPro data-project % pytest -v day1_종합실습/test_pipeline.py
rootdir: /Users/gayeon/data-project/data-project
plugins: cov-7.1.0, anyio-4.14.2
collected 7 items

day1_종합실습/test_pipeline.py::test_weather_response_is_valid PASSED [ 14%]
day1_종합실습/test_pipeline.py::test_invalid_precipitation_probability_is_rejected PASSED [ 28%]
day1_종합실습/test_pipeline.py::test_different_weather_list_lengths_are_rejected PASSED [ 42%]
day1_종합실습/test_pipeline.py::test_negative_population_is_rejected PASSED [ 57%]
day1_종합실습/test_pipeline.py::test_failed_ip_response_is_rejected PASSED [ 71%]
day1_종합실습/test_pipeline.py::test_build_dataframe_row_count PASSED [ 85%]
day1_종합실습/test_pipeline.py::test_invalid_temperature_type_is_rejected PASSED [100%]

===== 7 passed in 0.42s =====
(.venv) gayeon@sunggayeonui-MacBookPro data-project % ruff check day1_종합실습
All checks passed!
```

```
● (.venv) gayeon@sunggayeonui-MacBookPro data-project % clear
  pytest -q "day1_종합실습/test_pipeline.py"
  ruff check "day1_종합실습"
  .....
  7 passed in 0.42s
  All checks passed!
○ (.venv) gayeon@sunggayeonui-MacBookPro data-project %
```

- GIT 연동

```
Total 13 (delta 0), reused 0 (delta 0), pack-reused 0 (from 0)
To https://github.com/gayeon9-9/day1_python_data_project.git
* [new branch]      main -> main
branch 'main' set up to track 'origin/main'.
● (.venv) gayeon@sunggayeonui-MacBookPro data-project % git log --oneline -5
ee2d1b2 (HEAD -> main, origin/main) Day1 비동기 API 데이터 파이프라인 완성
○ (.venv) gayeon@sunggayeonui-MacBookPro data-project %
```

Code 분석 결과에 대한 본인 의견

Day1 종합실습 코드 분석 및 의견

Open-Meteo, Countries.dev, ip-api 이렇게 총 3개의 API에서 데이터 가져옴
asyncio.gather()를 사용하면 3개의 API를 동시에 실행하며 비동기 실행이 순차 실행에 비해 대기 시간을 줄여준다는 것을 확인함

수집한 데이터는 Pydantic v2로 타입과 범위를 검증 -> API 응답이 성공하더라도 잘못된 값이 들어올 수 있기 때문에 데이터를 저장하기 전에 검증하는 과정이 필요하다는 것을 확인

CSV와 Parquet의 성능 비교

데이터가 74건으로 적어서 CSV가 더 빠르고 파일 크기도 작았음 => 무조건 Parquet이 좋은 것이 아니라 데이터 크기와 사용 목적에 맞게 저장 형식을 선택할 필요성을 느낌

추가로 개선한다면 API 호출 실패 시 재시도하는 기능과 타임아웃을 넣거나, 성능을 여러 번 측정해서 평균값을 비교하면 더 정확한 결과를 확인할 수 있을 것 같음